

# Nastroje na amerykańskim rynku kapitałowym. Krótkookresowe prognozy indeksu S&P 500

Projekt zaliczeniowy z przedmiotu „Prognozowanie Gospodarcze”

Krystyna Turkowska (50%),

Julia Zawadzka (50%)

Analityka gospodarcza, II stopień,

Uniwersytet Ekonomiczny w Krakowie

Kraków, 2026

## 1. Wprowadzenie i uzasadnienie ekonomiczne projektu

Rynek akcji Stanów Zjednoczonych odgrywa szczególną rolę w globalnym systemie finansowym, a indeks S&P 500 stanowi jego najbardziej charakterystyczną miarę. Obejmuje on największe spółki notowane na amerykańskiej giełdzie oraz kluczowe sektory gospodarki. Z tego względu zmiany wartości indeksu są powszechnie interpretowane jako barometr kondycji gospodarczej, poziomu niepewności oraz nastrojów inwestorów. W praktyce poziom indeksu interpretowany jest jako bieżąca wycena przyszłych dochodów przedsiębiorstw oraz zagregowanych oczekiwań inwestorów dotyczących koniunktury gospodarczej. Z tego względu zmiany wartości indeksu S&P 500 traktowane są jako barometr nastrojów gospodarczych oraz wyprzedzający wskaźnik cyklu koniunkturalnego.

Celem niniejszego projektu jest krótkookresowe prognozowanie zmian indeksu S&P 500. W tym celu posłużono się cenami na zamknięcie. Prognoza poziomu indeksu wskazuje oczekiwany przyszły poziom wyceny rynku akcji, co przekłada się na wartość majątku gospodarstw domowych i przedsiębiorstw. Poziom indeksu ma znaczenie nie tylko dla inwestorów finansowych, lecz także dla całej gospodarki: wzrost wartości aktywów zwiększa skłonność do konsumpcji i inwestycji, natomiast spadki ograniczają wydatki i podnoszą awersję do ryzyka.

Prognozowanie krótkookresowych zmian cen aktywów finansowych jest jednym z najbardziej wymagających obszarów ekonometrii. Zgodnie z hipotezą efektywności rynku ceny akcji odzwierciedlają wszystkie dostępne informacje, przez co przyszłe poziomy indeksu są trudne do przewidzenia. Jednocześnie obserwacje empiryczne wskazują, że poziomy indeksów wykazują trwałe trendy oraz silne powiązania obecnego poziomu rynku z poziomami z przeszłości. Oznacza to, że pomimo występowania zmian, które mogą mieć charakter losowy, sam proces kształtowania poziomu indeksu nie jest czysto przypadkowy i może być modelowany przy użyciu narzędzi ekonometrii szeregów czasowych.

W praktyce gospodarczej prognozy takie pełnią przede wszystkim funkcję informacyjną i zarządczą. Wykorzystywane są przez szeroką grupę interesariuszy.

Banki centralne analizują zachowanie rynku akcji jako element wpływający na funkcjonowanie gospodarki. Spadki indeksów mogą sygnalizować narastające napięcia finansowe i pogorszenie oczekiwań co do wzrostu gospodarczego, natomiast wzrosty — poprawę nastrojów i potencjalny wzrost konsumpcji. Krótkoterminowe prognozy pomagają ocenić stabilność systemu finansowego oraz skutki prowadzonej polityki pieniężnej.

Instytucje finansowe wykorzystują prognozy do zarządzania ryzykiem portfela inwestycyjnego. Nawet niewielka poprawa trafności prognoz może istotnie poprawić jakość strategii zabezpieczającej i pomóc w planowaniu kolejnych decyzji. W tym kontekście ważniejsza od przewidywania kierunku trendu bywa ocena krótkoterminowej dynamiki rynku.

Inwestorzy stosują prognozy w strategiach tradingowych. W krótkim horyzoncie czasowym decyzje inwestycyjne często zależą od bieżącej dynamiki rynku, a nie od fundamentów gospodarczych. Oczekiwany poziom indeksu wpływa na wybór momentu wejścia lub wyjścia z rynku.

Przedsiębiorstwa obserwują rynek akcji przy podejmowaniu decyzji finansowych, takich jak emisja akcji, skup własny czy finansowanie inwestycji. Wysoki poziom indeksu oznacza niższy koszt kapitału własnego i sprzyja finansowaniu inwestycji, natomiast spadki ograniczają możliwości pozyskania kapitału.

Decydenci publiczni i regulatorzy traktują rynek kapitałowy jako wskaźnik stabilności gospodarki. Nagłe zmiany indeksu mogą wskazywać na napięcia systemowe, wymagające reakcji politycznej lub regulacyjnej.

Z makroekonomicznego punktu widzenia poziom indeksu S&P 500 pełni funkcję wyprzedzającego wskaźnika koniunktury. Rynek finansowy przetwarza informacje szybciej niż statystyki gospodarcze publikowane z opóźnieniem, dlatego zmiany indeksu często poprzedzają zmiany

produkcji, zatrudnienia czy konsumpcji. Prognozowanie jego wartości pozwala zatem pośrednio przewidywać kierunek aktywności gospodarczej.

Jednocześnie trudność prognozowania rynku finansowego stanowi aspekt argumentujący przeprowadzenie analizy tego procesu. Jeżeli proste modele statystyczne nie poprawiają jakości prognoz względem prognozy naiwnej, oznacza to wysoką efektywność rynku i brak krótkookresowej przewidywalności. Jeżeli natomiast modele lepiej opisują przyszłe poziomy indeksu, sugeruje to istnienie krótkotrwałych struktur informacyjnych i opóźnień w reakcji inwestorów. W obu przypadkach wynik badania ma istotną interpretację ekonomiczną.

Wybór krótkiego horyzontu prognozy wynika z charakteru procesu. W długim okresie poziom indeksu determinowany jest czynnikami fundamentalnymi, takimi jak wzrost gospodarczy czy inflacja, które trudno modelować wyłącznie na podstawie przeszłych obserwacji szeregu czasowego. Natomiast w krótkim okresie dominują mechanizmy rynkowe, takie jak momentum, inercja cen czy reakcje na informacje, które mogą być uchwycone przez modele statystyczne.

Podsumowując, projekt posiada zarówno praktyczne, jak i poznawcze uzasadnienie ekonomiczne. Po pierwsze, dotyczy jednego z najważniejszych wskaźników globalnej gospodarki, którego zachowanie wpływa na decyzje wielu podmiotów ekonomicznych. Po drugie, stanowi empiryczny test stopnia przewidywalności rynku kapitałowego. Otrzymane wyniki pozwolą ocenić, czy krótkookresowe zmiany indeksu zawierają informację prognostyczną, czy też zachowują się zgodnie z hipotezą błędzenia losowego.

## **2. Wstępna charakterystyka procesu**

W badaniu analizie poddano dzienne dane dotyczące cen zamknięcia indeksu S&P 500, obejmujące okres od początku stycznia 2010 roku do końca stycznia 2026 roku. Dane pobrano z serwisu Stooq. W celu lepszego scharakteryzowania rzeczywistego procesu, wykres szeregu czasowego oraz analizę statystyk opisowych stworzono dla surowych danych. Natomiast ze względu na rosnącą w czasie zmienność dane wykorzystane do dalszych badań zostały zlogarytmowane.

Wykres 1. Ceny indeksu S&P 500



Źródło: Opracowanie własne na podstawie danych Stooq

Wizualizacja szeregu czasowego cen zamknięcia umożliwiła identyfikację głównych cech charakterystycznych dla rynku akcji USA. Obserwacje wykazały silny trend wzrostowy w długim okresie, odzwierciedlający akumulację kapitału, inflację oraz ogólną ekspansję gospodarczą, a także liczne epizody zwiększonej zmienności w krótkim okresie, typowe dla rynków finansowych, wynikające z napływu informacji ekonomicznych, geopolitycznych oraz decyzji instytucji finansowych.

Analiza danych pozwala również wyróżnić wyraźne momenty kryzysowe i nagłe wahania cen, które miały istotny wpływ na dynamikę indeksu. Do najważniejszych należą: okres pandemii COVID-19 w marcu 2020 roku czy epizody kryzysów finansowych w 2011–2012 oraz napięcie geopolitycznych w 2022 roku, powodujące krótkotrwałe, ale znaczące skoki zmienności. Takie wydarzenia pokazują, że rynek nie tylko reaguje na trendy fundamentalne, lecz także jest wrażliwy na nagłe szoki informacyjne, co ma kluczowe znaczenie dla analizy krótkoterminowej i konstrukcji modeli prognostycznych.

Analiza statystyk opisowych dla indeksu S&P 500, zestawionych w poniższej tabeli, wskazuje na znaczną zmienność i asymetrię badanego procesu.

Tabela 1. Statystyki opisowe S&P 500

| Statystyka             | Wartość    |
|------------------------|------------|
| Liczba obserwacji      | 5871       |
| Średnia                | 2967.15    |
| Minimum                | 1022.58    |
| I kwartył (Q1)         | 1818.32    |
| Mediana                | 2599.95    |
| III kwartył (Q3)       | 4108.74    |
| Maksimum               | 6978.60    |
| Wariancja              | 2293421.08 |
| Odchylenie standardowe | 1514.40    |
| Skośność               | 0.79       |
| Kurtoza                | -0.31      |

Źródło: Opracowanie własne

Już na poziomie podstawowych miar tendencji centralnej widać istotną różnicę między średnią a medianą wartości indeksu. Średnia wartość S&P 500 na poziomie 2967,15 przewyższa medianę wynoszącą 2599,95, co jest oznaką prawostronnej asymetrii rozkładu. Ten podwyższony poziom średniego indeksu jest w dużej mierze efektem kilku epizodów bardzo wysokich wartości indeksu, a nie trwałego przesunięcia całego rozkładu w górę. Ekonomicznie można to interpretować jako fakt, że przez większość badanego okresu indeks oscylował w umiarkowanych przedziałach wartości, natomiast skoki w górę – choć stosunkowo rzadkie – miały znaczny wpływ na poziom średniej.

Rozstęp międzykwartyłowy, wynoszący 2290,42, wraz z odchyleniem standardowym, potwierdza dużą zmienność procesu. Wartości indeksu w badanym okresie często odbiegały od średniego poziomu, co wskazuje na silną wrażliwość rynku na impulsy makroekonomiczne, wydarzenia finansowe oraz sytuacje kryzysowe.

Dodatnia skośność rozkładu oznacza, że rozkład wartości indeksu jest prawoskośny. Natomiast ujemna kurtoza sygnalizuje, że rozkład jest bardziej płaski niż rozkład normalny. Wskazuje to na większe rozproszenie wartości wokół średniej oraz rzadsze występowanie skrajnych odchyleń w stosunku do rozkładu normalnego.

Dalej niezbędna jest weryfikacja stacjonarności, ponieważ większość klasycznych metod modelowania i prognozowania, a w szczególności modele z rodziny ARIMA, wymaga, aby analizowany proces był stacjonarny lub możliwy do sprowadzenia do takiej postaci poprzez odpowiednie przekształcenia. W przypadku danych finansowych problem ten nabiera szczególnego znaczenia, gdyż ceny aktywów wykazują silną zależność od przeszłych obserwacji oraz obecny jest trend. Prognozowanie poziomów cen bez uprzedniego usunięcia niestacjonarności może prowadzić do regresji pozornej i w konsekwencji do błędnej interpretacji przewidywalności rynku.

W związku z tym zastosowano dwa uzupełniające się testy stacjonarności: ADF oraz KPSS. W teście ADF hipoteza zerowa zakłada występowanie pierwiastka jednostkowego, a przez to i niestacjonarności szeregu. Natomiast w teście KPSS hipotezą zerową jest stacjonarność procesu. Ich łączne zastosowanie zwiększa wiarygodność oceny własności szeregu i ogranicza ryzyko jego błędnej klasyfikacji. Analizę przeprowadzono zarówno dla poziomów cen zamknięcia indeksu S&P 500, jak i dla pierwszych różnic. Uzyskane rezultaty zaprezentowano w tabeli 2.

*Tabela 2. Wyniki testów stacjonarności S&P 500 (ADF i KPSS) dla danych zlogarytmowanych*

| Ujęcie              | Test | Statystyka | P-Value | Wniosek             |
|---------------------|------|------------|---------|---------------------|
| Dane zlogarytmowane | ADF  | -4,10      | <0,01   | Stacjonarność       |
| Dane zlogarytmowane | KPSS | 47,64      | <0,01   | Brak stacjonarności |
| 1. Różnice          | ADF  | -18,43     | <0,01   | Stacjonarność       |
| 1. Różnice          | KPSS | 0,03       | >0,1    | Stacjonarność       |

Źródło: Opracowanie własne

W ujęciu danych zlogarytmowanych zauważalna jest sprzeczność między wynikami testów. Test ADF sugeruje stacjonarność, podczas gdy test KPSS zdecydowanie ją odrzuca. Taka sytuacja może wynikać z faktu, że test ADF często błędnie interpretuje silny trend deterministyczny jako powrót do średniej. Bezpośrednie wykorzystanie logarytmów cen w analizie mogłoby prowadzić do uzyskania niewiarygodnych, pozornych zależności statystycznych.


Natomiast analiza pierwszych różnic przynosi jednoznaczne i spójne rezultaty. W tym przypadku oba testy potwierdzają stacjonarność szeregu: statystyka ADF jest bardzo niska, co silnie odrzuca hipotezę o niestacjonarności, a test KPSS uzyskuje wartość przy p-value większym niż 0,1, co wskazuje brak podstaw do odrzucenia hipotezy o stacjonarności. Proces zróżnicowanych zlogarytmowanych danych jest więc stabilny.

Na podstawie testów można stwierdzić, że dane S&P 500 są szeregiem zintegrowanym w stopniu pierwszym. Niestacjonarność danych zlogarytmowanych jednoznacznie wyklucza ich bezpośrednie modelowanie przy użyciu klasycznych modeli autoregresyjnych. Konieczne jest przeprowadzenie różnicowania danych używanych do budowy modeli, które wymagają stałości parametrów statystycznych w czasie.

Uzupełnienie analizy statystyk opisowych stanowi dekompozycja szeregu czasowego przeprowadzona z wykorzystaniem metody STL. Jej celem jest rozdzielenie obserwowanego przebiegu indeksu na trzy podstawowe komponenty: trend, wahania sezonowe oraz składnik losowy. Takie

podejście umożliwia oddzielenie systematycznych zmian wartości indeksu od krótkotrwałych wahań wynikających z bieżących informacji rynkowych.

Wykres 2. Dekompozycja indeksu S&P 500 metodą STL (dane zlogarytmowane)



Źródło: Opracowanie własne na podstawie danych Stooq


Wyniki dekompozycji zlogarytmowanych cen indeksu S&P 500 wskazują przede wszystkim na dominującą rolę trendu. Widoczny jest wyraźny, względnie gładki wzrost indeksu w długim okresie, przerywany jedynie epizodami silnych zaburzeń związanych z wydarzeniami makroekonomicznymi, takimi jak kryzysy finansowe czy nagłe zmiany polityki pieniężnej. Ceny akcji są w dużej mierze determinowane przez trwałe czynniki ekonomiczne, a krótkookresowe odchylenia mają charakter przejściowy.

Sezonowość została oszacowana dla tygodniowych okresów. Ceny zamknięcia w weekendy są cenami zamknięcia ostatniej sesji. Wykres przypomina czarny pasek ze względu na ściśnięcie wyników bardzo dużej liczby tygodni. Wyraźnie widać jednak, że komponent ten osiąga niewielkie wartości w relacji do pozostałych elementów szeregu. Wskazuje to na subtelne efekty kalendarzowe, związane z rytmem tygodnia handlowego, które jednak nie odgrywają istotnej roli w kształtowaniu poziomu indeksu. Jest to zgodne z hipotezą efektywności rynku – silna i stabilna sezonowość stwarzałaby możliwość osiągania ponadprzeciętnych zysków arbitrażowych i powinna z czasem zanikać.

Największą zmienność wykazuje składnik losowy, oscylujący wokół zera i charakteryzujący się epizodami podwyższonej amplitudy w okresach zwiększonej niepewności rynkowej. Odpowiada on krótkookresowym reakcjom inwestorów na napływ nowych informacji oraz zmianom nastrojów rynkowych. Otrzymana struktura szeregu potwierdza zatem, że indeks giełdowy można interpretować jako proces zdominowany przez trend, na który nakładają się krótkotrwałe szoki informacyjne.

W celu przyjrzenia się dokładniej efektowi tygodniowemu poniżej załączono wykres przedstawiający wartości komponentu sezonowego uzyskane z dekompozycji STL dla zlogarytmowanych cen indeksu S&P 500, pogrupowane według dni tygodnia (dni sesyjne).

Wykres 3. Rozkład sezonowości S&P 500 (dane zlogarytmowane)



Źródło: Opracowanie własne na podstawie danych Stooq


Różnice pomiędzy dniami są rzędu kilku setnych promila wartości indeksu, co oznacza, że efekt kalendarzowy ma znaczenie marginalne względem trendu i losowej zmienności rynku.

Można jednak zauważyć subtelny schemat. Poniedziałek cechuje się przeciętnie ujemnym odchyleniem od trendu – tzw. efekt poniedziałku, interpretowany jako reakcja rynku na skumulowane informacje z weekendu. Środa i piątek wykazują dodatnie odchylenia – często wiązane z publikacjami danych makroekonomicznych oraz zamykaniem pozycji przed weekendem. Wtorek i czwartek są bliskie wartości neutralnej.

Efekt dnia tygodnia istnieje, lecz jego siła jest bardzo mała i niewystarczająca do systematycznego prognozowania poziomu indeksu. Zastosowanie modeli sezonowych nie przyniosłoby więc znaczącej poprawy jakości prognoz.

Wykonano także analizę inercji i struktury opóźnień, która służy do identyfikacji własności dynamicznych badanego szeregu czasowego oraz doboru odpowiedniej klasy modeli prognostycznych. Można ją przeprowadzić przy użyciu korelogramów ACF (funkcja autokorelacji) i PACF (autokorelacja cząstkowa).

Wykres 4. Analiza korelogramów (dane zlogarytmowane)



Źródło: Opracowanie własne na podstawie danych Stooq


Funkcja autokorelacji utrzymuje się na bardzo wysokim poziomie bliskim jedności nawet dla odległych opóźnień i wygasa bardzo powoli. Taki kształt ACF jest charakterystyczny dla szeregów niestacjonarnych z trendem stochastycznym. Bieżąca wartość indeksu jest w znacznym stopniu zdeterminowana przez jego przeszłe poziomy, a wpływ wcześniejszych obserwacji nie zanika w czasie. W ujęciu ekonomicznym odpowiada to mechanizmowi kumulacji informacji na rynku kapitałowym – nowe informacje są trwale wbudowywane w ceny aktywów, przez co poziomy indeksu nie powracają do stałej średniej.

Funkcja cząstkowej autokorelacji wykazuje pojedynczą, wyraźnie istotną statystycznie wartość dla pierwszego opóźnienia, natomiast dalsze opóźnienia mieszczą się w granicach przedziału ufności. Bezpośrednia zależność występuje więc głównie pomiędzy kolejnymi obserwacjami.

Łączna interpretacja wykresów ACF i PACF potwierdza, że zlogarytmowany indeks S&P 500 to proces zintegrowany rzędu pierwszego  $I(1)$ . W konsekwencji modelowanie powinno opierać się na szeregu po różnicowaniu.

Przeanalizowano także korelogramy dla pierwszych różnic logarytmów, aby upewnić się, że sprowadzają proces do stacjonarności.

Wykres 5. Analiza korelogramów (pierwsze różnice logarytmów)



Źródło: Opracowanie własne na podstawie danych Stooq

Dane na wykresie wizualnie oscylują wokół stałej średniej bliskiej zeru. Choć widoczne są okresy podwyższonej zmienności, brak wyraźnego trendu sugeruje, że różnicowanie rzeczywiście pomogło sprowadzić proces do postaci stacjonarnej.

Funkcja autokorelacji (ACF) wykazuje kilka istotnych statystycznie wartości dla niskich opóźnień, w szczególności dla pierwszego i drugiego opóźnienia. Warto jednak zauważyć, że wartości te, choć istotne, są relatywnie niskie, a dla dalszych opóźnień funkcja szybko wygasa i przyjmuje wartości nieistotne. Taki rozkład sugeruje, że w szeregu występuje słaba pamięć krótkookresowa, co może wskazywać na proces typu średniej ruchomej.

Funkcja cząstkowej autokorelacji (PACF) wskazuje na istotność początkowych opóźnień. Gwałtowne "ucięcie się" istotnych wartości PACF po pewnym czasie jest sygnałem, że struktura zależności może być opisana modelem autoregresyjnym niskiego rzędu.

Łączna interpretacja wykresów pozwala stwierdzić, że o ile zlogarytmowany indeks S&P 500 jest niestacjonarny, o tyle różnice logarytmiczne wykazują cechy procesu stacjonarnego z bardzo słabą, ale zauważalną autokorelacją krótkookresową. W kontekście ekonometrycznym sugeruje to, że model ARIMA byłby odpowiednim narzędziem do opisu dynamiki tego szeregu. Model ETS natomiast pozwoli na elastyczne ujęcie komponentu trendu, który w analizie STL okazał się dominujący, oraz ewentualne wygładzenie składnika losowego przy nadaniu większej wagi obserwacjom najświeższym. Z kolei Random Walk z dryfem bezpośrednio adresuje stochastyczny charakter trendu wzrostowego indeksu. Dodatkowo zastosowanie metody naiwnej posłuży jako punkt odniesienia.

### 3. Estymacja modeli prognostycznych i selekcja specyfikacji

Celem kolejnego etapu badania była identyfikacja i estymacja modeli prognostycznych, które w najbardziej precyzyjny sposób oddają mechanizm generujący dynamikę indeksu S&P 500, przy jednoczesnym zachowaniu wysokiej sprawności predykcyjnej. Modele wyznaczane były w sposób automatyczny.

Jako pierwszy wybrano model klasy ARIMA. Modele te stanowią fundament analizy finansowej, gdyż pozwalają na jednoczesne ujęcie autoregresji oraz średniej ruchomej po uprzednim sprowadzeniu szeregu do stacjonarności. Z punktu widzenia rynków kapitałowych, ARIMA jest w stanie wychwycić krótkookresowe zależności liniowe oraz mechanizm korygowania się cen po wystąpieniu szoków informacyjnych, co czyni ją standardowym narzędziem weryfikacji słabej formy efektywności rynku.

Drugą klasą modeli uwzględnioną w analizie był model ETS, oparty na wygładzaniu wykładniczym w ujęciu przestrzeni stanów. Modele te charakteryzują się wyjątkową zdolnością do adaptacji wag dla najświeższych obserwacji, co jest kluczowe na rynku akcji, gdzie stare dane szybko tracą na znaczeniu prognostycznym. Model ETS automatycznie identyfikuje strukturę trendu (addytywną lub multiplikatywną), co pozwala na elastyczne dopasowanie do długookresowych cykli koniunkturalnych indeksu S&P 500.

Trzecią specyfikacją jest model błędzenia losowego z dryfem, zaimplementowany jako przypadek szczególny modelu ARIMA(0,1,0). Wybór ten posiada uzasadnienie w teorii finansów i hipotezie błędzenia losowego. Model zakłada, że najlepszą prognozą przyszłej ceny jest cena bieżąca skorygowana o stały parametr dryfu, odpowiadający historycznej stopie zwrotu. Włączenie tej specyfikacji pozwala sprawdzić, czy złożone struktury ARIMA rzeczywiście dostarczają istotnej informacji ponad prosty, liniowy trend wzrostowy wynikający z długookresowej ekspansji gospodarczej.

Ostatnią metodą uwzględnioną w porównaniu była metoda naiwna, pełniąca rolę benchmarku dla pozostałych specyfikacji. Opiera się na założeniu, że najlepszą prognozą na jutro jest wartość z dnia dzisiejszego. Stanowi rygorystyczny test dla modeli zaawansowanych, ponieważ bezpośrednio odnosi się do hipotezy o efektywności rynku w wersji słabej – jeśli inne modele ekonometryczne nie mogą wygenerować błędów niższych niż model naiwny, oznacza to, że zmiany cen są nieprzewidywalne i mają charakter czystego szumu losowego. Odrzucenie modeli złożonych na rzecz metody naiwnej następuje w sytuacji, gdy błąd prognozy ex-post tych pierwszych jest wyższy, co wskazuje na to, że algorytmy dokonały nadmiernego dopasowania, czyli overfittingu do przypadkowych wahań, zamiast wychwycić rzeczywisty sygnał.

Estymacja modeli została przeprowadzona na zbiorze uczącym obejmującym obserwacje od początku 2010 roku do grudnia 2024 roku. Przy doborze parametrów kierowano się zasadą brzytwy Ockhama, szukając równowagi między prostotą modelu a jego skutecznością. W tym celu wykorzystano kryteria informacyjne AIC, AICc oraz BIC, które nakładają karę za nadmierną złożoność modelu i ograniczają ryzyko przeuczenia. Modele naiwny oraz błędzenie losowe z dryfem nie posiadają wyznaczonych tych wskaźników, ponieważ które nie optymalizują funkcji wiarygodności w taki sam sposób jak ARIMA czy ETS.


*Tabela 3. Kryteria informacyjne – S&P 500 (zbiór uczący)*

| <b>Model</b>         | <b>AIC</b> | <b>AICc</b> | <b>BIC</b> |
|----------------------|------------|-------------|------------|
| <b>ARIMA</b>         | -36041     | -36041      | -36015     |
| <b>ETS</b>           | -4437      | -4437       | -4417      |
| <b>NAIVE</b>         | -          | -           | -          |
| <b>RW WITH DRIFT</b> | -          | -           | -          |

Źródło: Opracowanie własne

Analiza uzyskanych wyników jednoznacznie wskazuje na przewagę modelu ARIMA nad modelem ETS w badanym szeregu S&P 500. Duża rozbieżność sugeruje, że struktura ARIMA, bazująca na różnicowaniu i korelacji opóźnień, znacznie lepiej oddaje specyfikę zlogarytmowanych danych giełdowych niż algorytmy wygładzania wykładniczego. Ostateczne potwierdzenie jego użyteczności nastąpi jednak podczas porównania błędów prognoz ex-post z modelem naiwnym oraz błędzeniem losowym.

Wykres 6. Diagnostyka reszt w czasie



Źródło: Opracowanie własne na podstawie danych Stooq

Dla najlepszego modelu wybranego na podstawie kryteriów informacyjnych, którym okazał się model ARIMA (1,1,1), przeprowadzono diagnostykę reszt. Jej celem jest sprawdzenie, czy informacja z danych historycznych szeregu czasowego S&P 500 została wyczerpana, czego oznaką jest pozostanie szum losowy. Wizualna ocena wykresu reszt potwierdza, że proces jest centrowany wokół zera, co świadczy o braku systematycznego obciążenia prognoz. Niemniej jednak, w szeregu wyraźnie zaznacza się zjawisko heteroskedastyczności. Jest to szczególnie widoczne w okresie zawirowań rynkowych około 2020 roku, gdzie amplituda wahań reszt gwałtownie wzrosła, co sugeruje, że model ARIMA, mimo poprawnego opisu trendu, nie w pełni radzi sobie z modelowaniem dynamiki zmienności.

Analiza wykresu ACF dla reszt sugeruje niedostateczne dopasowanie modelu do struktury danych. Liczne wartości autokorelacji wyraźnie przekraczają przedziały ufności.

Badanie rozkładu reszt za pomocą histogramu dopełnia obrazu diagnostycznego. Rozkład jest leptokurtyczny o grubych ogonach. Odejście od założenia o normalności rozkładu błędu losowego wskazuje, że model jest podatny na błędy wynikające z występowania obserwacji odstających.

Podsumowując, pomimo wskazania kryteriów informacyjnych na model ARIMA, przeprowadzona dla niego diagnostyka wykazała, problemy ze specyfikacją. Decydujący wpływ na wybór ostatecznego modelu będzie miała analiza błędu ex-post.

#### 4. Walidacja ex-post i strukturalna analiza błędów predykcyjnych

Zadaniem walidacji ex post jest ocena faktycznej zdolności progностycznej modeli w warunkach zbliżonych do realnej praktyki analitycznej. W odróżnieniu od kryteriów informacyjnych, opisujących jakość dopasowania do danych wykorzystanych w estymacji, sprawdza, jak model prognozuje obserwacje niewykorzystane wcześniej w procesie uczenia. Z tego powodu to najistotniejszy element oceny przydatności modelu.

Zastosowano podejście podziału danych na zbiór treningowy i testowy. Modele oszacowane na danych do grudnia 2024 roku zostały następnie użyte do stworzenia prognoz dla 2025 roku i stycznia 2026 roku, aby zapewnić jak największą aktualność prognoz. Następnie otrzymane wyniki zostały porównane z rzeczywistymi wartościami w tym okresie. Tak skonstruowana procedura eliminuje ryzyko przeuczenia oraz pozwala na ocenę stabilności predykcyjnej modeli w niepewnym i ciągle zmieniającym się otoczeniu.

Ewaluacja trafności prognoz została przeprowadzona z wykorzystaniem zróżnicowanego zestawu wskaźników, co zapewniło wszechstronny wgląd w jakość otrzymanych wyników. Wykorzystano mierniki bezwzględne (MSE, RMSE, MAE) do określenia typowej skali odchyleń oraz miary względne (MPE, MAPE), które pozwoliły na analizę błędu w ujęciu procentowym i kierunkowym. Kluczowym etapem badania była dekompozycja współczynnika Theila ( $I_1$ ,  $I_2$ ,  $I_3$ ). Dzięki niej możliwe było precyzyjne wskazanie przyczyn niedokładności oraz weryfikacja poprawności konstrukcji samego modelu.

Tabela 4. Pełna walidacja ex-post – indeks S&P 500 (dokładność do 4 miejsc)

| Model         | MSE    | RMSE | MAE | MPE    | $I_1$ (Bias) | $I_2$ (Var) | $I_3$ (Cov) | Theil $I_2$ |
|---------------|--------|------|-----|--------|--------------|-------------|-------------|-------------|
| ARIMA         | 90922  | 302  | 232 | -0,749 | 0,00644      | 0,649       | 0,347       | 0,048       |
| ETS           | 330574 | 575  | 477 | 4,89   | 0,352        | 0,64        | 0,00924     | 0,0915      |
| NAIVE         | 323117 | 568  | 472 | 4,8    | 0,348        | 0,642       | 0,0114      | 0,0905      |
| RW WITH DRIFT | 88811  | 298  | 225 | -0,922 | 0,0142       | 0,623       | 0,365       | 0,0474      |

Źródło: Opracowanie własne

Uzyskane wartości mierników bezwzględnych, w szczególności najniższe w zestawieniu poziomy RMSE oraz MAE dla modelu błędzenia losowego z dryfem, potwierdzają jego zdolność do precyzyjnego ograniczania skali błędów. Tak niski poziom odchyleń w porównaniu z modelem naiwnym świadczy o wysokiej wartości informacyjnej wynikającej z uwzględnienia dryfu i struktury autokorelacji w procesie generowania prognoz.

Szczegółowa analiza dekompozycji współczynnika Theila wskazuje na model błędzenia losowego z dryfem lub ARIMA. W obu przypadkach udział błędu obciążenia jest marginalny, co oznacza, że modele te niemal bezbłędnie identyfikują średni poziom badanego zjawiska. Najistotniejszą część błędu stanowi komponent kowariancyjny. Otrzymane wartości sugeruje, że modele poprawnie

odczytały tendencję i dynamikę szeregu, a pozostałe niedokładności wynikają jedynie z niemożliwych do przewidzenia, losowych fluktuacji.

W przeciwieństwie do liderów zestawienia, modele ETS oraz naiwny charakteryzują się niekorzystną strukturą błędów, co rzutuje na ich użyteczność analityczną. Mimo że wskaźnik zmienności pozostaje w nich na zbliżonym poziomie, to dominujący udział błędu obciążenia wskazuje na poważne wady strukturalne. Modele te systematycznie rozmiągają się z rzeczywistym poziomem zjawiska, co potwierdza również dodatnia wartość wskaźnika MPE, świadcząca o powtarzalnym niedoszacowaniu prognoz. Zastosowanie tych metod wiąże się z wysokim ryzykiem błędu systematycznego.

Podsumowując, za najbardziej wiarygodny model można uznać błędzenie losowe z dryfem, które charakteryzuje się najniższymi błędami prognozy oraz optymalnymi wartościami dekompozycji współczynnika Theila.


## **5. Prognoza ex-ante indeksu S&P 500 i implikacje ekonomiczne**

O ile walidacja ex-post służyła jako rygorystyczny test jakości narzędzi na danych historycznych, o tyle prognoza ex-ante stanowi fundament procesów decyzyjnych w inwestowaniu. To ona determinuje oczekiwania odnośnie do przyszłych stóp zwrotu i pozwala na aktywne zarządzanie ryzykiem w portfelu akcyjnym.

Zgodnie z wynikami oceny jakościowej, jako finalne narzędzie prognostyczne wybrano model błędzenia losowego z dryfem i stworzono z jego pomocą prognozy ex-ante indeksu S&P 500 na nadchodzące 12 miesięcy. Wybór tego modelu jest spójny z hipotezą rynku efektywnego, według której zmiany cen aktywów o wysokiej płynności są w krótkim okresie nieprzewidywalne, a najlepszą bazą dla przyszłych szacunków jest aktualna cena skorygowana o długookresowy trend. Po ustaleniu optymalnej specyfikacji model został ponownie oszacowany na pełnym zbiorze danych, co pozwoliło na maksymalne wykorzystanie informacji z najświeższych notowań i precyzyjne wyznaczenie parametru dryfu.

Wyniki predykcji zaprezentowano w formie wykresu wachlarzowego, uwzględniającego przedziały ufności na poziomach 80% oraz 95%. Wizualizacja ta pokazuje, że wraz z wydłużaniem się horyzontu czasowego, zakres możliwych odchyłeń od prognozy centralnej sukcesywnie rośnie.

Wykres 7. Wykres wachlarzowy prognoz indeksu S&P 500



Źródło: Opracowanie własne

Prognoza punktowa sugeruje kontynuację wzrostu indeksu. Ścieżka ta zakłada, że pomimo krótkoterminowych szumów i wahań o charakterze losowym, rynek w horyzoncie rocznym będzie dążył do odzwierciedlenia tendencji długookresowego trendu. Należy jednak pamiętać, że model ten, opierając się na założeniu błędzenia losowego, nie próbuje przewidywać konkretnych korekt, lecz wskazuje na najbardziej prawdopodobny kierunek zmian w oparciu o ich historyczną dynamikę.

Natomiast prognozy przedziałowe uwzględniają różne scenariusze - od znacznego wzrostu cen indeksu S&P 500 do nawet jego spadku. Oszacowane przez nie wartości pozwalają na bardziej realistyczną ocenę przyszłych zmian i wcześniejsze przygotowanie przez podmioty gospodarki strategii uwzględniających różne warianty.